

ĐÁNH GIÁ ICH PRIOR TRONG PHÂN ĐOẠN PHÙ NÃO QUANH Ổ XUẤT HUYẾT TRÊN ẢNH CT

ĐOÀN ANH VŨ¹, HOÀNG VĂN QUÝ^{1,*}

¹*Bộ môn Công nghệ Thông tin, Phân hiệu Trường Đại học Thủy lợi,
TP. Hồ Chí Minh, Việt Nam*

E-mail address: doananhvu15011609@gmail.com (Đ. A. Vũ); hoangvanquy@tlu.edu.vn (H. V. Quý)

Tóm tắt. Phù não quanh ổ xuất huyết (perihematoma edema, PHE) là một dấu hiệu quan trọng trên ảnh CT sọ não không tiêm thuốc ở bệnh nhân xuất huyết não tự phát. Khác với vùng xuất huyết nội sọ (intracranial hemorrhage, ICH), PHE thường có biên mờ, cường độ xám chồng lấp với nhu mô não lân cận và thể tích nhỏ, vì vậy bài toán phân đoạn tự động vẫn còn nhiều thách thức. Bài báo này xây dựng một khung đánh giá có đối chứng nhằm kiểm tra giả thuyết: thông tin ICH prior có thể hỗ trợ mô hình phân đoạn PHE tốt hơn so với đầu vào CT đơn thuần hay không. Hệ thống được thiết kế theo hai giai đoạn: (1) huấn luyện mô hình ICH teacher trên dữ liệu ngoài Instance2022 và Seg-CQ500 để sinh prior vùng xuất huyết; (2) huấn luyện mô hình PHE downstream trên PHE-SICH-CT-IDS với các cấu hình CT-only, teacher-prior và pseudo-prior. nnU-Net 3d_fullres được sử dụng làm backbone chính, trong khi MedNeXt, DynUNet, SwinUNETR và ResidualUNet3D được dùng như đối chứng phụ. Kết quả cho thấy nnU-Net CT-only đạt Dice mean 0.3941 và IoU mean 0.2710, là baseline ổn định nhất trong nhóm PHE-only. ICH teacher cải tiến nâng Dice mean từ 0.7330 lên 0.7758 ở bài toán ICH, nhưng lợi ích này không chuyển hóa rõ rệt sang PHE downstream. Các cấu hình có prior chỉ tăng nhẹ hoặc tương đương baseline; pseudo-prior cải tiến đạt IoU mean cao nhất 0.2769 nhưng đồng thời làm FP tăng mạnh, thể hiện xu hướng over-phân đoạn. Từ đó, bài báo kết luận rằng ICH prior là hướng có cơ sở giải phẫu, nhưng cần thiết kế lại biểu diễn prior, đặc biệt theo dạng ring/distance quanh máu tụ, thay vì đưa trực tiếp vùng ICH vào mô hình PHE.

Từ khóa. CT sọ não, ICH prior, nnU-Net, phân đoạn ảnh y sinh, phù não quanh ổ xuất huyết, PHE-SICH-CT-IDS, pseudo-prior.

1. GIỚI THIỆU

Xuất huyết não tự phát (spontaneous intracerebral hemorrhage, SICH) là một cấp cứu thần kinh có nguy cơ tử vong và di chứng cao. Trong quy trình lâm sàng, CT sọ não không tiêm thuốc thường là phương tiện hình ảnh đầu tay vì có khả năng phát hiện vùng máu tụ nhanh, rộng rãi và phù hợp với bối cảnh cấp cứu. Bên cạnh thể tích và vị trí máu tụ, phù não quanh ổ xuất huyết (PHE) phản ánh tổn thương thứ phát quanh ổ máu tụ, liên quan tới hiệu ứng choán chỗ, thay đổi áp lực nội sọ và diễn tiến thần kinh sau xuất huyết [1, 2, 3]. Do đó, phân đoạn PHE chính xác có ý nghĩa không chỉ trong định lượng tổn thương mà còn trong theo dõi tiến triển và xây dựng các mô hình hỗ trợ quyết định.

Tuy nhiên, PHE khó phân đoạn hơn ICH trên CT. Vùng ICH thường có mật độ cao và tương phản rõ hơn so với nền nhu mô não, trong khi PHE có cường độ thấp hơn, biên không sắc nét và dễ lẫn với chất trắng, não thất hoặc nhiễu do cửa sổ hiển thị. Ngoài ra, nhiều ca PHE trong tập kiểm thử có thể tích nhỏ; khi đó chỉ một sai lệch vài voxel cũng làm Dice giảm mạnh. Sự hạn chế về dữ liệu công khai càng làm bài toán khó hơn, vì mô hình học sâu 3D thường cần nhiều ca được gán nhãn voxel-level để học được hình thái tổn thương đa dạng. Bộ dữ liệu PHE-SICH-CT-IDS được công bố nhằm giải quyết phần nào khoảng trống này với 120 CT scans và 7,022 ảnh CT kèm nhãn PHE [4]. Tuy vậy, quy mô 120 ca vẫn tương đối nhỏ so với yêu cầu của các mô hình phân đoạn 3D

hiện đại.

Trong bối cảnh dữ liệu nhỏ, nnU-Net là một lựa chọn hợp lý vì framework này tự cấu hình nhiều bước quan trọng như resampling, chuẩn hóa, patch size, batch size, kiến trúc U-Net và chiến lược hậu xử lý theo từng bài toán mới [5]. Tuy nhiên, câu hỏi chính của nghiên cứu này không chỉ là chọn backbone nào cho Dice cao hơn. Trọng tâm của bài báo là kiểm tra xem thông tin giải phẫu từ ICH có thể đóng vai trò prior không gian để hỗ trợ PHE hay không. Về mặt lâm sàng, PHE thường phân bố quanh ổ máu tụ chứ không xuất hiện độc lập. Vì vậy, một mô hình ICH teacher được huấn luyện từ dữ liệu ngoài có thể sinh bản đồ xác suất/mask vùng xuất huyết, sau đó dùng làm kênh bổ sung cho mô hình PHE downstream.

Tuy nhiên, giả thuyết này cũng có rủi ro. PHE không trùng với ICH; nếu prior được đưa vào quá trực tiếp, mô hình có thể học lệch về vùng máu tụ thay vì vùng phù quanh máu tụ. Ngoài ra, chất lượng ICH teacher tốt chưa chắc đảm bảo cải thiện PHE, vì bottleneck có thể nằm ở cách biểu diễn prior, cách ghép kênh đầu vào, loss function hoặc hậu xử lý. Vì vậy, nghiên cứu này bổ sung một nhánh pseudo-prior sinh trực tiếp từ CT bằng ngưỡng HU, Otsu cục bộ và morphology. Nhánh này đóng vai trò đối chứng để kiểm tra lợi ích của prior đến từ kiến thức teacher hay chỉ từ tín hiệu cường độ ảnh có sẵn trong CT.

Các đóng góp chính của bài báo gồm:

1. **Khung đánh giá ICH prior có đối chứng:** xây dựng pipeline gồm baseline CT-only, teacher-prior và pseudo-prior trên cùng split PHE-SICH-CT-IDS, tránh so sánh rời rạc giữa các notebook hoặc cấu hình khác nhau.
2. **Phân tích chuyển giao từ ICH sang PHE:** huấn luyện ICH teacher trên Instance2022 và Seg-CQ500, đánh giá cải thiện của teacher, sau đó kiểm tra liệu cải thiện này có chuyển thành cải thiện PHE downstream hay không.
3. **Diễn giải lỗi theo Dice, IoU và FP/FN/TP:** không chỉ báo cáo chỉ số overlap trung bình mà còn phân tích xu hướng over-phân đoạn, under-phân đoạn, biến thiên theo từng ca và tác động của hậu xử lý.

Phần còn lại của bài báo được tổ chức như sau. Mục 2 trình bày tổng quan nghiên cứu và các câu hỏi nghiên cứu. Mục 3 mô tả kiến trúc pipeline, dữ liệu, tiền xử lý, cơ chế tích hợp prior và cấu hình huấn luyện. Mục 4 trình bày kết quả thực nghiệm, so sánh với các backbone đối chứng và phân tích lỗi. Mục 5 kết luận và đề xuất hướng phát triển.

2. TỔNG QUAN NGHIÊN CỨU

Phân đoạn tổn thương não trên CT đã được nghiên cứu rộng rãi trong các bài toán ICH, nhồi máu não và chấn thương sọ não. Với ICH, tín hiệu tăng tỉ trọng trên CT giúp mô hình học sâu dễ nhận diện hơn so với các vùng phù não có biên mờ. Các benchmark như INSTANCE2022 cung cấp dữ liệu ICH 3D có nhãn voxel-level và nhấn mạnh đặc điểm dị hướng của CT sọ não không tiêm thuốc [6]. Ngoài ra, Seg-CQ500 bổ sung nhãn phân đoạn ICH cho 51 CT scans từ CQ500, hỗ trợ cộng đồng nghiên cứu trong việc so sánh các phương pháp phân đoạn xuất huyết [7, 8]. Các nguồn dữ liệu này phù hợp để huấn luyện teacher cho bài toán ICH nhưng không trực tiếp cung cấp nhãn PHE.

Đối với PHE, số lượng bộ dữ liệu công khai ít hơn đáng kể. PHE-SICH-CT-IDS là một trong những nguồn dữ liệu quan trọng vì tập trung trực tiếp vào PHE trong SICH, có nhãn cho phân đoạn ngữ nghĩa, phát hiện đối tượng và trích xuất đặc trưng radiomics [4]. Sự xuất hiện của bộ dữ liệu này cho phép đánh giá PHE một cách hệ thống hơn, nhưng vẫn đặt ra thách thức do số ca hạn chế, độ không đồng nhất hình thái tổn thương và sự khác biệt giữa lát cắt có PHE rõ và lát cắt PHE rất nhỏ.

Về mô hình, U-Net và các biến thể encoder-decoder vẫn là nền tảng chính của phân đoạn y sinh. nnU-Net cho thấy sức mạnh ở chỗ không chỉ là một kiến trúc, mà là một framework tự cấu hình toàn bộ pipeline theo đặc điểm dữ liệu [5]. Các mô hình hiện đại hơn như MedNeXt hiện đại

hóa ConvNet 3D theo tinh thần ConvNeXt/Transformer và hướng tới bối cảnh dữ liệu y tế ít nhãn [10]; SwinUNETR sử dụng encoder Transformer phân cấp để khai thác quan hệ dài hạn trong ảnh 3D [11]; MONAI cung cấp nhiều mô hình và công cụ chuẩn hóa quy trình thực nghiệm y tế [9]. Tuy nhiên, khi dữ liệu nhỏ và tổn thương có biên mờ, mô hình lớn hơn không luôn đảm bảo tốt hơn. Kết quả thực nghiệm trong báo cáo này cũng cho thấy đổi backbone đơn thuần chưa vượt được nnU-Net 3d_fullres.

Một hướng khác là dùng prior giải phẫu hoặc prior không gian. Trong bài toán PHE, ICH là nguồn prior tự nhiên vì PHE thường nằm quanh máu tụ. Tuy nhiên, prior phải được thiết kế cẩn thận: nếu mô hình nhận trực tiếp mask ICH, nó có thể nhầm mục tiêu PHE với vùng máu tụ; nếu dùng distance transform hoặc ring prior, mô hình có thêm thông tin về khoảng cách tới ICH nhưng vẫn phải học vùng phù xung quanh. Bài báo này đặt trọng tâm vào câu hỏi chuyển giao prior, thay vì chỉ tối ưu một backbone.


Từ các hạn chế trên, nghiên cứu đặt ra ba câu hỏi:

- **RQ1:** ICH teacher được huấn luyện trên dữ liệu ngoài có cải thiện được PHE downstream so với baseline CT-only hay không?
- **RQ2:** Pseudo-prior sinh trực tiếp từ CT có đạt mức tương đương teacher-prior hay không, và điều này nói gì về nguồn gốc tín hiệu prior?
- **RQ3:** Khi thêm prior, lỗi voxel-level thay đổi theo hướng nào: tăng TP, giảm FN hay tăng FP dẫn đến over-phân đoạn?

3. PHƯƠNG PHÁP NGHIÊN CỨU

3.1. Mô hình kiến trúc tổng quát

Khung thực nghiệm được thiết kế như một pipeline hai giai đoạn, trong đó giai đoạn đầu tạo tri thức phụ trợ về ICH và giai đoạn sau dùng tri thức này cho bài toán PHE. Hình 1 minh họa luồng chính. Ở nhánh trên, dữ liệu ngoài Instance2022 và Seg-CQ500 được dùng để huấn luyện mô hình ICH teacher. Sau khi teacher được đánh giá, mô hình này dự đoán ICH probability/mask trên PHE-SICH-CT-IDS. Ở nhánh dưới, mô hình PHE downstream được huấn luyện với ba nhóm đầu vào: CT-only, CT kết hợp teacher-prior và CT kết hợp pseudo-prior.



Hình 1: Kiến trúc tổng quát của khung đánh giá ICH prior cho phân đoạn PHE. Hình được vẽ lại theo hướng paper-style, loại bỏ khoảng trắng dư và chỉ giữ các khối thực nghiệm chính.

Về mặt logic, pipeline này tách rõ ba nguồn thông tin: ảnh CT gốc, prior từ teacher học trên

dữ liệu ngoài và pseudo-prior sinh bằng heuristic CT-only. Cách tách này giúp hạn chế việc kết luận sai rằng mọi cải thiện đều đến từ teacher. Nếu pseudo-prior đạt kết quả tương đương teacher-prior, điều đó gợi ý rằng cường độ ảnh và vị trí vùng tăng tỉ trọng đã chứa một phần tín hiệu prior; teacher chỉ có ích khi biểu diễn prior chuyển được thông tin giải phẫu bổ sung thay vì lặp lại tín hiệu có sẵn.

3.2. Các kiến trúc mô hình khảo sát

Nghiên cứu khảo sát hai nhóm mô hình. Nhóm thứ nhất là mô hình PHE-only, dùng CT làm đầu vào và không sử dụng ICH prior. Đây là nhóm baseline nhằm xác định mức hiệu năng tối thiểu cần vượt qua. Trong nhóm này, nnU-Net 3d_fullres được xem là backbone chính vì khả năng tự cấu hình mạnh trong phân đoạn y sinh. Các mô hình MedNeXt-S, MedNeXt-M, DynUNet, SwinUNETR và ResidualUNet3D được dùng như đối chứng phụ để kiểm tra giả thuyết “đổi backbone là đủ”.

Nhóm thứ hai là mô hình prior-guided. Teacher-prior sử dụng ICH probability/mask sinh bởi mô hình ICH teacher. Pseudo-prior không dùng teacher mà sinh prior từ CT bằng ngưỡng HU, Otsu cục bộ và morphology. Hai nhánh này được đưa vào cùng logic đánh giá với baseline để trả lời liệu prior có thật sự tạo cải thiện ổn định, hay chỉ làm mô hình tăng nhảy nhưng đồng thời tăng FP.

3.3. Thiết kế dữ liệu đa nguồn và thiết lập thực nghiệm

Bảng 1 tóm tắt ba bộ dữ liệu chính. PHE-SICH-CT-IDS là dữ liệu trung tâm cho PHE, còn Instance2022 và Seg-CQ500 đóng vai trò dữ liệu ngoài cho ICH teacher. Cách thiết kế này tránh dùng nhãn PHE để huấn luyện teacher, qua đó giảm nguy cơ rò rỉ thông tin giữa bước tạo prior và bước đánh giá PHE.

Bảng 1: Các bộ dữ liệu sử dụng trong nghiên cứu

Bộ dữ liệu	Đối tượng nhãn	Số ca nội bộ	Vai trò
PHE-SICH-CT-IDS	PHE mask	120	Dữ liệu chính để huấn luyện, validation và kiểm thử mô hình PHE downstream.
Instance2022	ICH mask	100 có label	Dữ liệu ngoài dùng để huấn luyện ICH teacher, cung cấp tri thức về vùng xuất huyết trên CT không tiêm thuốc.
Seg-CQ500	ICH mask	51 có label	Bổ sung dữ liệu ngoài cho ICH teacher nhằm tăng đa dạng hình thái ICH.

Split PHE-SICH-CT-IDS dùng trong các thí nghiệm chính được giữ cố định để đảm bảo các nhánh có thể so sánh trực tiếp. Bảng 2 cho thấy train split gồm 99 ca, validation 10 ca và test 11 ca. Test split có 329 slices, trong đó 62 slices có PHE, với tổng thể tích PHE 31.535 ml. Điều này cho thấy tập kiểm thử nhỏ và nhạy với từng ca, vì vậy kết quả phải được đọc cùng phân tích per-case thay vì chỉ dựa vào trung bình.


Bảng 2: Thống kê split PHE-SICH-CT-IDS dùng cho các thí nghiệm chính

Split	Cases	Slices	PHE-positive slices	Tổng PHE volume	Vai trò
Train	99	2983	560	355.116 ml	Huấn luyện mô hình PHE.
Validation	10	289	61	34.999 ml	Chọn checkpoint và kiểm soát overfit.
Test	11	329	62	31.535 ml	Đánh giá cuối trên split khóa.
Tổng	120	3601	683	421.650 ml	Toàn bộ PHE-SICH nội bộ.


3.4. Pipeline tiền xử lý dữ liệu

Các thí nghiệm chính sử dụng cơ chế tiền xử lý của nnU-Net 3d_fullres, bao gồm chuẩn hóa spacing, crop foreground, xác định patch size và batch size phù hợp với dữ liệu. Với baseline CT-only, đầu vào chỉ gồm một kênh CT. Với teacher-prior, đầu vào được mở rộng thành nhiều kênh gồm CT, ICH probability/mask và distance transform từ vùng ICH. Với pseudo-prior, kênh prior được sinh trực tiếp từ CT thay vì từ teacher.

Việc đồng bộ không gian giữa các kênh là điều kiện bắt buộc. Tất cả mask/prior phải được đưa về cùng spacing, orientation và kích thước với CT volume tương ứng. Nếu prior bị lệch vài voxel, mô hình downstream có thể học sai quan hệ giữa máu tụ và phù não. Vì vậy, các bước tạo prior không được xem là tiền xử lý phụ, mà là một phần quan trọng của pipeline thực nghiệm.



(a) Ca ICH teacher có Dice cao.



(b) Ca khó hoặc Dice thấp hơn.

Hình 2: Minh họa QC của ICH teacher sau khi cắt bỏ khoảng trắng dư. Các ảnh quá nhỏ hoặc chủ yếu là progress plot được loại khỏi bản paper vì không đóng góp trực tiếp cho lập luận chính.

3.5. Cơ chế tích hợp ICH prior dựa trên xác suất và khoảng cách

Đối với nhánh teacher-prior, mô hình ICH teacher nhận CT volume X và sinh bản đồ xác suất ICH:

$$P_{\text{ICH}}(v) = f_{\theta}^{\text{ICH}}(X)(v), \quad (1)$$

trong đó v là một voxel trong CT volume. Từ bản đồ xác suất này, mask ICH nhị phân được tạo bằng ngưỡng τ :

$$M_{\tau}(v) = \mathbb{I}[P_{\text{ICH}}(v) \geq \tau]. \quad (2)$$

Để tránh việc mô hình PHE học trùng vào chính vùng máu tụ, nghiên cứu bổ sung distance prior biểu diễn khoảng cách từ mỗi voxel tới vùng ICH:

$$D(v) = \min_{u \in M_{\tau}} \|v - u\|_2, \quad \tilde{D}(v) = \exp(-D(v)/\sigma), \quad (3)$$


trong đó σ điều chỉnh mức suy giảm theo khoảng cách. Biểu diễn này nhấn mạnh vùng lân cận quanh ICH, phù hợp hơn với giả thuyết giải phẫu rằng PHE nằm quanh máu tụ nhưng không đồng nhất với máu tụ.

Với nhánh pseudo-prior, prior được sinh theo quy tắc CT-only:


$$M_{\text{pseudo}}(v) = \mathbb{K}[X(v) > 55 \text{ HU}] \cap B_{\text{brain}} \cap \Omega_{\text{Otsu}}, \quad (4)$$

trong đó B_{brain} là vùng não sau bước skull-stripping/brain mask, còn Ω_{Otsu} là vùng được giữ lại sau ngưỡng Otsu cục bộ và morphology. Pseudo-prior không nhằm thay thế hoàn toàn teacher, mà là đối chứng để kiểm tra liệu thông tin cường độ CT có đủ tạo prior hữu ích hay không.


Biểu diễn prior: không thay nhãn PHE, chỉ bổ sung kênh gợi ý không gian



Hình 3: Cơ chế biểu diễn prior. Prior không thay thế nhãn PHE mà được dùng như kênh bổ sung giúp mô hình học quan hệ không gian giữa máu tụ và phù não.



(a) ICH prior do teacher sinh trên PHE-SICH.



(b) Pseudo-ICH prior sinh trực tiếp từ CT.

Hình 4: Minh họa trực quan hai loại prior sau khi cắt khoảng trắng. Teacher-prior có tính học được từ dữ liệu ngoài, còn pseudo-prior phản ánh tín hiệu cường độ và hình thái học từ CT.

3.6. Chiến lược phân đoạn hai giai đoạn

Giai đoạn 1 là huấn luyện ICH teacher trên dữ liệu ngoài. Mục tiêu của giai đoạn này không phải đánh giá PHE, mà là tạo mô hình có khả năng nhận diện vùng xuất huyết. Teacher càng tốt thì prior càng đáng tin cậy; tuy nhiên, teacher tốt chỉ là điều kiện cần, không phải điều kiện đủ cho cải thiện PHE.

Giai đoạn 2 là huấn luyện PHE downstream trên PHE-SICH-CT-IDS. Trong giai đoạn này, các cấu hình được giữ cùng backbone chính và cùng split để so sánh công bằng. Baseline CT-only cho biết năng lực của mô hình khi không có prior. Teacher-prior cho biết tác động của prior học từ dữ liệu ngoài. Pseudo-prior cho biết mức độ mà heuristic CT-only có thể mô phỏng teacher-prior.

Bảng 3 tóm tắt các cấu hình chính. Điểm quan trọng là nhánh pseudo-prior không dùng ICH teacher, vì vậy nếu nó đạt kết quả gần teacher-prior thì cần diễn giải thận trọng: lợi ích có thể đến từ việc thêm kênh thông tin cường độ/không gian, chứ không nhất thiết từ tri thức teacher.

Bảng 3: Cấu hình các thí nghiệm chính

Thiết lập	Vai trò	Đầu vào	Cấu hình chính	Mục đích
Baseline CT-only	PHE baseline	CT only	nnU-Net 3d_fullres, 250 epochs	Mốc so sánh chính cho PHE-only.
ICH teacher cải tiến	ICH teacher	External CT + ICH mask	Instance2022 + Seg-CQ500, 250 epochs	Sinh ICH probability/mask để làm prior.
Teacher-prior cải tiến	Teacher-prior PHE	CT + ICH probability + distance prior	nnU-Net 3d_fullres, 250 epochs	Kiểm tra prior từ teacher có cải thiện PHE không.
Pseudo-prior cải tiến	Pseudo-prior PHE	Brain CT + subdural CT + pseudo-ICH probability + distance	Threshold 55 HU, local Otsu, morphology, 250 epochs	Đối chứng CT-only, không dùng ICH teacher.

3.7. Xử lý rủi ro chuyển giao prior

Rủi ro lớn nhất của prior-guided PHE segmentation là mô hình học sai mục tiêu. Nếu prior quá mạnh, mô hình có thể dự đoán lan quanh hoặc trùng vùng ICH, dẫn đến FP cao. Nếu prior quá yếu hoặc teacher bỏ sót ICH, mô hình có thể trở nên bảo thủ và làm FN tăng. Vì vậy, nghiên cứu dùng ba nguyên tắc:

1. **Không dùng nhãn PHE để tạo ICH prior:** teacher được huấn luyện trên dữ liệu ICH ngoài, còn PHE label chỉ dùng trong downstream.
2. **Đánh giá bằng cả overlap và thành phần lỗi:** Dice/IoU được đọc cùng FP, FN và TP để nhận diện over-phân đoạn hay under-phân đoạn.
3. **Không ưu tiên hậu xử lý nếu làm mất PHE nhỏ:** hậu xử lý chỉ được xem là có ích khi không làm giảm Dice hoặc sensitivity trên nhóm tổn thương nhỏ.

3.8. Cấu hình huấn luyện

Tất cả thí nghiệm chính được huấn luyện với số epoch tối đa 250 theo thiết lập trong báo cáo gốc. Với nnU-Net, nhiều tham số như patch size, batch size, resampling và normalization do framework tự xác định. Các mô hình đối chứng trong MONAI/custom pipeline được xem như kiểm tra phụ, không thay thế benchmark chính khi chưa có tối ưu sâu theo từng backbone.

Bảng 4: Cấu hình huấn luyện và đánh giá

Thành phần	Thiết lập
Backbone chính	nnU-Net 3d_fullres.
Số epoch	250 epochs cho các thí nghiệm chính được báo cáo.
Chiến lược đầu vào	CT-only; CT + binary ICH prior; CT + ICH probability + distance; CT + pseudo-prior.
Dữ liệu ngoài	Instance2022 + Seg-CQ500 chỉ dùng cho ICH teacher.
Chỉ số chính	Dice mean, Dice median, IoU mean.
Chỉ số phân tích lỗi	FP mean, FN mean, TP mean ở voxel-level; sensitivity ở mức detection.
Kiểm soát so sánh	Giữ cùng split PHE-SICH-CT-IDS cho các nhánh PHE downstream chính.

Các chỉ số overlap được định nghĩa như sau:

$$\text{Dice} = \frac{2TP}{2TP + FP + FN}, \quad \text{IoU} = \frac{TP}{TP + FP + FN}. \quad (5)$$

Trong bài toán PHE nhỏ, Dice có thể giảm mạnh khi FP hoặc FN tăng nhẹ. Vì vậy, báo cáo sử dụng thêm FP/FN/TP để xác định mô hình đang dự đoán quá rộng hay bỏ sót vùng phù.

4. KẾT QUẢ THỰC NGHIỆM

4.1. Môi trường thực nghiệm

Báo cáo gốc tập trung vào kết quả thuật toán và không cung cấp đầy đủ thông số phần cứng/latency chuẩn hóa. Vì vậy, trong bản paper này, môi trường thực nghiệm được mô tả theo hướng tái lập pipeline thay vì đưa ra số đo latency chưa được kiểm chứng. Các yếu tố quyết định khả năng tái lập gồm: cùng split PHE-SICH-CT-IDS, cùng dữ liệu ngoài cho ICH teacher, cùng số epoch cho các nhánh chính và cùng bộ chỉ số đánh giá.

Bảng 5: Môi trường và điều kiện tái lập thí nghiệm

Nhóm	Thành phần	Mô tả
Dữ liệu	PHE-SICH-CT-IDS	Split cố định 99/10/11 ca cho train/validation/test.
Dữ liệu ngoài	Instance2022, Seg-CQ500	Chỉ dùng để huấn luyện ICH teacher.
Framework chính	nnU-Net 3d_fullres	Tự cấu hình tiền xử lý và huấn luyện cho phân đoạn y sinh 3D.
Đối chứng phụ	MedNeXt, DynUNet, SwinUNETR, ResidualUNet3D	Dùng để kiểm tra tác động của việc đổi backbone.
Chỉ số đánh giá	Dice, IoU, FP/FN/TP	Đánh giá overlap và phân tích lỗi voxel-level.

4.2. Kết quả huấn luyện offline cho giai đoạn khởi tạo

Bảng 6 trình bày kết quả các backbone PHE-only. nnU-Net 3d_fullres đạt Dice mean 0.3941 và IoU mean 0.2710, là mốc cao nhất trong nhóm PHE-only. MedNeXt-S và MedNeXt-M có kết quả gần nhưng chưa vượt baseline, trong khi DynUNet thấp hơn. SwinUNETR và ResidualUNet3D giảm rõ rệt trong setting hiện tại, cho thấy các kiến trúc lớn hoặc phức tạp hơn không tự động giải quyết khó khăn của PHE khi dữ liệu nhỏ.

Bảng 6: Kết quả các backbone PHE-only trên test split


Thiết lập	Mô hình	Dice mean	IoU mean	Nhận xét
Baseline CT-only	nnU-Net 3d_fullres	0.3941	0.2710	Mốc PHE-only chính.
MedNeXt-S	MedNeXt-S	0.3627	0.2390	Chưa vượt nnU-Net.
MedNeXt-M	MedNeXt-M	0.3600	0.2356	Model lớn hơn nhưng chưa cải thiện.
DynUNet	DynUNet	0.3430	0.2242	Thấp hơn nnU-Net.
SwinUNETR	SwinUNETR	0.1163	0.0668	Không phù hợp setting hiện tại.
ResidualUNet3D	ResidualUNet3D	0.2161	0.1294	Tốt hơn SwinUNETR nhưng còn thấp.

Kết quả này củng cố vai trò của nnU-Net như baseline mạnh trong dữ liệu y sinh 3D quy mô nhỏ. Nếu không có thêm dữ liệu, tiền huấn luyện phù hợp hoặc tuning riêng cho từng backbone, việc thay kiến trúc đơn thuần chưa đủ tạo cải thiện ổn định.

Bảng 7 cho thấy ICH teacher cải tiến làm tăng Dice mean từ 0.7330 lên 0.7758, IoU/Jaccard từ 0.6211 lên 0.6644 và precision từ 0.7562 lên 0.8107; đồng thời giảm sai số thể tích tuyệt đối từ 4.117 ml xuống 3.141 ml. Điều này chứng minh stage ICH teacher có cải thiện thật sự. Tuy nhiên, cải thiện ở ICH không tự động đảm bảo PHE downstream tăng, vì PHE là vùng quanh máu tụ chứ không phải chính máu tụ.

Bảng 7: So sánh ICH teacher gốc và ICH teacher cải tiến

Thiết lập	Dice mean	Dice median	IoU/Jaccard	Precision	Recall	Volume abs error
ICH teacher gốc	0.7330	0.8548	0.6211	0.7562	0.7598	4.117 ml
ICH teacher cải tiến	0.7758	0.8581	0.6644	0.8107	0.7739	3.141 ml

**Hình 5:** So sánh các chỉ số overlap của ICH teacher gốc và ICH teacher cải tiến.


4.3. Kết quả giai đoạn PHE downstream

Bảng 8 là kết quả quan trọng nhất. Teacher-prior gốc đạt Dice mean 0.3999, cao hơn CT-only 0.3941 nhưng mức tăng nhỏ. Dice median tăng rõ từ 0.3638 lên 0.5021, cho thấy một số ca được ổn định hơn nhờ prior. Tuy nhiên, mức tăng này đi kèm FP tăng, như trình bày ở Bảng 9. Teacher-prior cải

tiền dùng prior mềm hơn và distance transform nhưng Dice mean 0.3974, không vượt teacher-prior gốc và chỉ xấp xỉ baseline. Điều này cho thấy teacher tốt hơn chưa đủ; cách mã hóa prior và cách mô hình dùng prior mới là nút thắt.

Bảng 8: Chỉ số overlap của các nhánh PHE downstream trên test split chính

Thiết lập	Đầu vào	Dice mean	Dice median	IoU mean
Baseline CT-only	CT only	0.3941	0.3638	0.2710
Teacher-prior gốc	CT + binary ICH prior	0.3999	0.5021	0.2750
Teacher-prior cải tiến	CT + ICH probability + distance	0.3974	0.4560	0.2686
Pseudo-prior gốc	CT + pseudo-ICH probability + distance	0.3995	0.3699	0.2725
Pseudo-prior cải tiến	Brain/subdural CT + pseudo-prior	0.3978	0.4339	0.2769




Hình 6: So sánh Dice mean và IoU mean giữa các nhánh PHE chính. Các biến thể có prior chỉ nhìn hơn hoặc tương đương baseline; khoảng cách nhỏ nên chưa đủ để kết luận prior tạo bước nhảy mạnh.

Pseudo-prior là đối chứng đáng chú ý. Pseudo-prior gốc đạt Dice mean 0.3995, gần bằng teacher-prior gốc dù không dùng teacher external. Pseudo-prior cải tiến đạt IoU mean cao nhất 0.2769 và median Dice 0.4339, nhưng Dice mean 0.3978 vẫn không vượt rõ baseline. Điều này cho thấy prior có tín hiệu, nhưng tín hiệu đó chưa được kiểm soát đủ tốt để tạo cải thiện ổn định ở mọi ca.

Bảng 9: Phân rã lỗi voxel-level của các nhánh PHE downstream

Thiết lập	FP mean	FN mean	TP mean	Diễn giải nhanh
Baseline CT-only	1455.2	1127.2	1324.8	Cân bằng hơn.
Teacher-prior gốc	1876.0	1033.5	1418.5	TP tăng, FN giảm nhưng FP tăng vừa.
Teacher-prior cải tiến	1513.8	1196.4	1255.6	FP giảm so với teacher-prior gốc nhưng FN tăng.
Pseudo-prior gốc	1354.5	1157.5	1294.5	FP thấp hơn nhưng FN vẫn cao.
Pseudo-prior cải tiến	2324.5	899.9	1552.1	TP cao và FN thấp nhưng FP rất cao.



Hình 7: Phân rã FP/FN/TP của các nhánh PHE chính. Nhánh pseudo-prior cải tiến làm tăng TP và giảm FN, nhưng FP cũng tăng mạnh, thể hiện xu hướng over-phân đoạn.

4.4. So sánh với các phương pháp hiện đại và phân tích đối chứng

So với các backbone hiện đại, nnU-Net CT-only vẫn là mốc ổn định nhất trong setting này. MedNeXt được thiết kế cho dữ liệu y tế ít nhãn, nhưng kết quả MedNeXt-S và MedNeXt-M lần lượt đạt Dice mean 0.3627 và 0.3600, chưa vượt nnU-Net. SwinUNETR có khả năng mô hình hóa quan hệ dài hạn nhưng trong thí nghiệm hiện tại chỉ đạt Dice mean 0.1163, có thể do dữ liệu nhỏ, cấu hình chưa tối ưu hoặc khác biệt modality/task so với các bài toán mà Transformer thường phát huy. ResidualUNet3D đạt 0.2161, tốt hơn SwinUNETR nhưng vẫn thấp hơn rõ rệt.

Điểm đáng chú ý là các nhánh prior-guided không tạo khoảng cách lớn so với baseline. Điều này làm cho kết luận khoa học trở nên thận trọng hơn: ICH prior đúng về mặt giải phẫu, nhưng biểu diễn prior hiện tại chưa đủ tốt để chuyển hóa thành cải thiện PHE rõ rệt. Teacher-prior gốc tăng median Dice nhưng làm FP tăng; teacher-prior cải tiến làm teacher ICH tốt hơn nhưng PHE chưa tăng; pseudo-prior đạt tương đương teacher-prior, chứng minh cần đối chứng CT-only để tránh quy kết sai nguồn cải thiện.

4.5. Phân tích chi phí, hậu xử lý và khả năng triển khai

Bảng 10 cho thấy pseudo-prior cải tiến đạt sensitivity 1.0000 ở ngưỡng thể tích dự đoán 0.5 ml trên toàn bộ 11 ca test. Tuy nhiên, predicted mean volume là 4.351 ml, cao hơn ground-truth mean volume 2.867 ml. Với nhóm PHE nhỏ ≤ 5 ml, ground-truth mean chỉ 1.452 ml nhưng predicted mean 3.891 ml. Đây là bằng chứng rõ cho xu hướng over-phân đoạn: mô hình bắt được ca dương tính nhưng dự đoán vùng phù rộng hơn thực tế.

Bảng 10: Detection-level summary của pseudo-prior cải tiến ở ngưỡng thể tích dự đoán 0.5 ml


Cohort	n	TP	FN	Sensitivity	GT mean ml	Pred mean ml
Toàn bộ test	11	11	0	1.0000	2.867	4.351
PHE nhỏ ≤ 5 ml	8	8	0	1.0000	1.452	3.891
PHE > 5 ml	3	3	0	1.0000	6.639	5.579

Phân tích per-case ở Bảng 11 và Hình 8 cho thấy biến thiên lớn giữa các bệnh nhân. Ca phe_0167 có Dice 0.0000 vì không có TP; ca phe_0113 đạt Dice 0.1132 dù FN rất thấp, do FP lên tới 3662 voxel; ngược lại, các ca tốt như phe_0084, phe_0096 và phe_0002 đạt Dice từ 0.6611 đến

0.7321. Điều này giải thích vì sao cần báo cáo cả mean, median và phân tích lỗi, đặc biệt khi test split chỉ có 11 ca.

Bảng 11: Các ca khó nhất và tốt nhất của pseudo-prior cải tiến theo Dice

Nhóm	Case	Dice	IoU	FP	FN	TP
Khó nhất	phe_0167	0.0000	0.0000	1396	1185	0
Khó nhất	phe_0113	0.1132	0.0600	3662	6	234
Khó nhất	phe_0061	0.2036	0.1133	2770	47	360
Tốt nhất	phe_0084	0.7321	0.5775	1017	565	2162
Tốt nhất	phe_0096	0.7002	0.5387	3477	1087	5329
Tốt nhất	phe_0002	0.6611	0.4938	627	518	1117



Hình 8: Dice theo từng test case tiêu biểu của nhánh pseudo-prior cải tiến. Chênh lệch giữa các ca rất lớn, phản ánh độ nhạy của PHE segmentation với kích thước và hình thái tổn thương.

Hậu xử lý không phải lúc nào cũng hữu ích. Với PHE nhỏ, các quy tắc loại đảo nhỏ có thể xóa luôn vùng phù thật, làm median Dice giảm. Vì vậy, bản paper này ưu tiên raw output khi so sánh các nhánh chính. Hậu xử lý nên được tối ưu riêng theo validation, có thể dùng rule phụ thuộc thể tích dự đoán hoặc học hậu xử lý bằng mô hình nhẹ, thay vì áp dụng một ngưỡng cứng cho mọi ca.

Bảng 12: Nhận xét rủi ro và hướng cải thiện

Vấn đề	Bằng chứng từ kết quả	Hướng xử lý tiếp theo
Dữ liệu nhỏ và split nhạy	Test chỉ 11 ca, Dice biến thiên mạnh theo từng case.	Chạy k-fold hoặc external validation nếu có thêm dữ liệu.
Prior gây over-phân đoạn	Pseudo-prior cải tiến tăng TP nhưng FP mean tăng lên 2324.5.	Regularization, threshold tuning trên validation hoặc loss phạt FP.
Teacher tốt hơn nhưng downstream chưa tốt hơn	ICH teacher cải tiến tăng Dice/IoU ICH nhưng teacher-prior cải tiến không tăng PHE Dice.	Thiết kế ring/distance prior tập trung vùng quanh ICH thay vì vùng ICH.
Postprocess làm mất PHE nhỏ	Postprocess có nguy cơ xóa vùng phù nhỏ, làm giảm Dice/sensitivity.	Tách rule cho PHE nhỏ hoặc học hậu xử lý theo validation.

5. KẾT LUẬN

Bài báo đã xây dựng và đánh giá một pipeline phân đoạn PHE trên CT sọ não với ba hướng chính: baseline CT-only, teacher-prior và pseudo-prior. Kết quả cho thấy nnU-Net 3d_fullres dùng CT-only là baseline mạnh và ổn định nhất trong phạm vi dữ liệu hiện tại, đạt Dice mean 0.3941 và IoU mean 0.2710. Các backbone thay thế như MedNeXt, DynUNet, SwinUNETR và ResidualUNet3D chưa tạo cải thiện ổn định, cho thấy khó khăn cốt lõi không chỉ nằm ở lựa chọn kiến trúc.

ICH teacher cải tiến đạt kết quả tốt hơn teacher gốc ở bài toán ICH, với Dice mean tăng từ 0.7330 lên 0.7758 và volume abs error giảm từ 4.117 ml xuống 3.141 ml. Tuy nhiên, cải thiện này chưa chuyển hóa rõ rệt sang PHE downstream. Teacher-prior gốc tăng nhẹ Dice mean và tăng median Dice nhưng làm FP tăng; teacher-prior cải tiến cân bằng hơn nhưng không vượt baseline rõ ràng. Đối chứng pseudo-prior cho thấy prior sinh trực tiếp từ CT có thể đạt mức tương đương teacher-prior, đồng thời pseudo-prior cải tiến đạt IoU mean cao nhất 0.2769 nhưng đi kèm FP cao. Vì vậy, kết luận chính không phải là “ICH prior vô dụng”, mà là biểu diễn prior hiện tại chưa đủ tối ưu để biến tri thức ICH thành cải thiện PHE bền vững.

Hướng phát triển tiếp theo gồm: đánh giá k-fold để giảm phụ thuộc split, thiết kế ring prior hoặc signed distance transform tập trung vùng quanh máu tụ, tối ưu loss cân bằng FP/FN, xây dựng hậu xử lý riêng cho PHE nhỏ và bổ sung external validation. Trong phạm vi dữ liệu hiện tại, đóng góp quan trọng nhất của nghiên cứu là một khung so sánh có đối chứng, có phân tích lỗi và có diễn giải trung thực về giới hạn chuyển giao từ ICH segmentation sang PHE segmentation.

TÀI LIỆU

- [1] S. M. Greenberg, W. C. Ziai, C. Cordonnier, D. Dowlatshahi, B. Francis, J. N. Goldstein, et al., “2022 guideline for the management of patients with spontaneous intracerebral hemorrhage: A guideline from the American Heart Association/American Stroke Association,” *Stroke*, vol. 53, no. 7, pp. e282–e361, 2022. doi: 10.1161/STR.0000000000000407.
- [2] Y. Chen, Z. Chen, L. Liu, and J. Liu, “Perihematomal edema after intracerebral hemorrhage,” *Frontiers in Immunology / related review literature*, 2021. Available: <https://pmc.ncbi.nlm.nih.gov/articles/PMC8560684/>.
- [3] S. B. Murthy, H. K. Moradiya, J. Dawson, D. F. Hanley, W. C. Ziai, and K. N. Sheth, “Perihematomal edema and functional outcomes in intracerebral hemorrhage,” *Stroke*, 2015. doi: 10.1161/STROKEAHA.115.010054.
- [4] D. Ma, C. Li, L. Qiao, T. Du, D. Tang, Z. Ma, M. Grzegorzec, and H. Sun, “PHE-SICH-CT-IDS: A benchmark CT image dataset for evaluation semantic segmentation, object detection and radiomic feature extraction of perihematomal edema in spontaneous intracerebral hemorrhage,” *Scientific Data*, 2024. arXiv:2308.10521.
- [5] F. Isensee, P. F. Jaeger, S. A. A. Kohl, J. Petersen, and K. H. Maier-Hein, “nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation,” *Nature Methods*, vol. 18, pp. 203–211, 2021. doi: 10.1038/s41592-020-01008-z.
- [6] X. Li, G. Luo, K. Wang, H. Wang, J. Liu, X. Liang, J. Jiang, Z. Song, C. Zheng, H. Chi, et al., “The state-of-the-art 3D anisotropic intracranial hemorrhage segmentation on non-contrast head CT: The INSTANCE challenge,” arXiv:2301.03281, 2023.
- [7] A. Spahr, et al., “Label-efficient deep semantic segmentation of intracranial hemorrhage,” 2023. Seg-CQ500 labels for intracranial hemorrhage segmentation.
- [8] Seg-CQ500, “Intracranial hemorrhages segmentation labels for 51 CT-scans from the CQ500 dataset,” Zenodo, 2023. Available: <https://zenodo.org/records/8063221>.

- [9] M. J. Cardoso, W. Li, R. Brown, et al., “MONAI: An open-source framework for deep learning in healthcare,” arXiv:2211.02701, 2022.
- [10] S. Roy, G. Koehler, C. Ulrich, M. Baumgartner, J. Petersen, F. Isensee, P. F. Jaeger, and K. H. Maier-Hein, “MedNeXt: Transformer-driven scaling of ConvNets for medical image segmentation,” arXiv:2303.09975, 2023.
- [11] A. Hatamizadeh, V. Nath, Y. Tang, D. Yang, H. R. Roth, and D. Xu, “Swin UNETR: Swin Transformers for semantic segmentation of brain tumors in MRI images,” arXiv:2201.01266, 2022.
- [12] O. Ronneberger, P. Fischer, and T. Brox, “U-Net: Convolutional networks for biomedical image segmentation,” *MICCAI*, pp. 234–241, 2015.